



**ΠΑΝΕΠΙΣΤΗΜΙΟ ΠΕΙΡΑΙΩΣ
ΤΜΗΜΑ ΨΗΦΙΑΚΩΝ ΣΥΣΤΗΜΑΤΩΝ**

**Μεταπτυχιακό Πρόγραμμα Σπουδών: Πληροφοριακά Συστήματα και
Υπηρεσίες**

Κατεύθυνση: Μεγάλα Δεδομένα και Αναλυτική

Μάθημα: Προγραμματισμός και Υποδομές Μεγάλων Δεδομένων: Python και
Νεφούπολογιστική

**Πρόβλεψη Φαρμακογενούς Αυτοανοσίας
(Drug-Induced Autoimmunity - DIA)**

Ομάδα Φοιτητών:

Μαρίνα Νούχου AM: 2423

Παναγιώτης Αθανασόπουλος AM: 2402

Ακαδημαϊκό Έτος: 2024-2025

Περιεχόμενα

1 Εισαγωγή	2
2 Δεδομένα	2
3 Ανάλυση Δεδομένων (EDA)	4
3.1 Διαστάσεις και Βασικά Στατιστικά	4
3.2 Κατανομή Τάξεων	4
3.3 Περιγραφική Στατιστική και Κανονικοποίηση	4
3.4 Συγκριτική Επισκόπηση Περιγραφέων	5
3.5 Ανάλυση PCA (Principal Component Analysis)	6
4 Μεθοδολογία	7
4.1 Προεπεξεργασία και Κανονικοποίηση	7
4.2 Εμπλουτισμός Χαρακτηριστικών: Tanimoto Graph Embeddings	7
4.3 Αντιμετώπιση Ανισορροπίας	7
4.4 Επιλογή Χαρακτηριστικών (Feature Engineering)	7
4.5 Μοντέλα και Εκπαίδευση	8
5 Αποτελέσματα	8
5.1 Συγκριτικός Πίνακας Μετρικών	8
5.2 Ανάλυση Αποτελεσμάτων	8
5.3 Confusion Matrices	9
5.4 Καμπύλες Precision-Recall και ROC	9
6 Συμπεράσματα	10

1. Εισαγωγή

Η πρόβλεψη της *Drug-Induced Autoimmunity* (DIA) αποτελεί κρίσιμη πρόκληση στην τοξικολογία φαρμάκων, καθώς οι σπάνιες αλλά σοβαρές αυτοάνοσες αντιδράσεις μπορούν να οδηγήσουν σε απόσυρση φαρμάκων ή σοβαρές παρενέργειες. Το dataset [14] περιλαμβάνει 597 φάρμακα (148 θετικά, 449 αρνητικά) και συνιστά ένα δυαδικό πρόβλημα ταξινόμησης με σημαντική ανισορροπία κατηγοριών (25% θετικά).

Πρόσφατες μελέτες έχουν παρουσιάσει σημαντικές επιδόσεις πάνω στο συγκεκριμένο dataset. Ενδεικτικά, η πλατφόρμα **InterDIA** [10] πρότεινε ένα ολοκληρωμένο και ερμηνεύσιμο πλαίσιο πρόβλεψης της DIA, βασισμένο σε μοριακές φυσικοχημικές ιδιότητες. Το μοντέλο χρησιμοποίησε τεχνικές όπως:

- **Multi-strategy feature selection**
- **Advanced ensemble resampling** για την αντιμετώπιση της ανισορροπίας
- **Easy Ensemble Classifier**, με επίδοση **AUC=0.8836** (CV) και **AUC=0.8930** (external test set)
- **SHAP** για μηχανιστική ερμηνεία των προβλέψεων (ιδιότητες όπως λιποφιλία, πολικότητα, φορτία)
- Δημιουργία **διαδικτυακής πλατφόρμας** για γρήγορη αξιολόγηση (Streamlit)

Η InterDIA κατέδειξε ότι μέσω σωστού χαρακτηρισμού μορίων και ερμηνευτικών μοντέλων, είναι εφικτή η πρόβλεψη ανοσοτοξικότητας, ακόμα και σε περιπτώσεις όπου η κλινική διάγνωση είναι πολύπλοκη. Παράλληλα, αξιοποιήθηκαν SHAP waterfall plots για κατανόηση του ρόλου κάθε χαρακτηριστικού σε επίπεδο μορίου.

Άλλη συγκριτική μελέτη από τους Delfiero et al. [4] συνέκρινε μοντέλα *XGBoost*, *CatBoost*, και *Gradient Boosting*, δείχνοντας ότι το *CatBoost* είχε το υψηλότερο ROC-AUC, ενώ το *XGBoost* πέτυχε την καλύτερη ισορροπία μεταξύ precision και recall. Και τα τρία μοντέλα πέτυχαν accuracy 87–89%, ενισχύοντας την ανάγκη αξιολόγησης με metrics όπως F1-score και MCC.

Το συγκεκριμένο πρόβλημα απαιτεί εξειδικευμένες προσεγγίσεις, λόγω της ανισορροπίας κλάσεων. Τεχνικές όπως **SMOTE**, **SMOTEENN**, **EasyEnsemble**, **cost-sensitive learning**, **threshold tuning** και **stacking ensembles** έχουν χρησιμοποιηθεί για τη βελτίωση recall και precision. Ταυτόχρονα, η επιλογή και ο εμπλουτισμός χαρακτηριστικών μέσω **RDKit**, **MOE**, ή **molecular fingerprints**, η χρήση **GNNs** και **transformer-based models**, και η βαθμονόμηση με **Bayesian optimization** έχουν συμβάλει στην αύξηση της απόδοσης.

Στόχος: Στόχος αυτής της εργασίας είναι η **βελτιστοποίηση μοντέλων πρόβλεψης της DIA**, εξετάζοντας και επεκτείνοντας τις υπάρχουσες προσεγγίσεις. Με κατάλληλο preprocessing, επιλογή χαρακτηριστικών, τεχνικές αντιμετώπισης ανισορροπίας και συνδυαστικά μοντέλα (*XGBoost*, *Random Forest*, *Logistic Regression*), επιχειρείται η επίτευξη **F1-score άνω του 75%**, με παράλληλη έμφαση στην **ερμηνευσιμότητα** και αξιοπιστία των προβλέψεων μέσω *SHAP*, *confusion matrices* και calibrated probabilities.

2. Δεδομένα

Το σύνολο δεδομένων που χρησιμοποιείται στην παρούσα μελέτη προέρχεται από το *UCI Machine Learning Repository* και αφορά την πρόβλεψη της εμφάνισης

αυτοανοσίας που προκαλείται από φαρμακευτικές ουσίες (**Drug-Induced Autoimmunity - DIA**) [14]. Περιλαμβάνει **597** φαρμακευτικά μόρια, περιγραφόμενα με **195 συν-νεχείς μοριακούς περιγραφείς (descriptors)** που έχουν εξαχθεί μέσω της βιβλιοθήκης RDKit.

Δομή Δεδομένων

Κάθε δείγμα (φαρμακευτικό μόριο) αναπαρίσταται ως μία γραμμή με τις εξής πληροφορίες:

- **195 descriptors:** Αριθμητικά χαρακτηριστικά που περιγράφουν μοριακές, φυσικοχημικές, τοπολογικές, ηλεκτρονικές και δομικές ιδιότητες του μορίου (π.χ. MolWt, TPSA, BalabanJ κ.ά.).
- **SMILES:** Αναπαράσταση της χημικής δομής σε μορφή string (δεν χρησιμοποιείται ως είσοδος στα μοντέλα).
- **Label:** Δυαδική ετικέτα στόχου — 1 για DIA-θετικά μόρια (προκαλούν αυτοανοσία) και 0 για DIA-αρνητικά.

Διαχωρισμός σε Εκπαιδευτικό και Δοκιμαστικό Σύνολο

Το dataset έχει ήδη διαχωριστεί σε:

- **Training Set:** 477 δείγματα (118 θετικά, 359 αρνητικά).
- **Test Set:** 120 δείγματα (30 θετικά, 90 αρνητικά).

Η αναλογία θετικών προς αρνητικά δείγματα είναι περίπου **1:3** σε κάθε σύνολο, γεγονός που καταδεικνύει πρόβλημα **ανισορροπίας κατηγορίας**, το οποίο πρέπει να ληφθεί υπόψη κατά τη μοντελοποίηση.

Πληρότητα Δεδομένων

Έγινε έλεγχος για ελλιπείς τιμές σε όλα τα πεδία (null / NaN), και διαπιστώθηκε ότι δεν υπάρχουν απουσιάζουσες τιμές στα δεδομένα. Όλα τα πεδία περιέχουν πλήρεις και έγκυρες εγγραφές.

Κατανομή Τάξεων

Η κατανομή των δειγμάτων ανά κατηγορία (Label) για το training set έχει ως εξής:

- **Label = 1 (DIA-Θετικά):** 118 δείγματα
- **Label = 0 (DIA-Αρνητικά):** 359 δείγματα

Αυτό αντιστοιχεί σε ποσοστό **24.7%** θετικών και **75.3%** αρνητικών, το οποίο αποτελεί έναν από τους βασικούς παράγοντες που επηρεάζουν την επιλογή μετρικών απόδοσης (π.χ. F1-score, Recall) αντί για απλή ακρίβεια (Accuracy).

Σκοπός Ανάλυσης

Στόχος μας είναι να εκπαιδεύσουμε ταξινομητές που θα προβλέπουν την ετικέτα **Label (0 ή 1)** με βάση τα **195 descriptors**, ώστε να εντοπίσουμε φάρμακα που ενδέχεται να προκαλέσουν αυτοανοσία. Έμφαση δίνεται όχι μόνο στην ακρίβεια πρόβλεψης, αλλά και στην **ερμηνευσιμότητα** των αποτελεσμάτων μέσω ανάλυσης χαρακτηριστικών.

3. Ανάλυση Δεδομένων (EDA)

Η διερευνητική ανάλυση δεδομένων (Exploratory Data Analysis - EDA) πραγματοποιήθηκε προκειμένου να κατανοηθούν τα βασικά χαρακτηριστικά του συνόλου δεδομένων DIA, να εντοπιστούν πιθανές ασυμμετρίες, να διαπιστωθεί η ανάγκη για κανονικοποίηση και να προετοιμαστεί κατάλληλα το σύνολο για μοντελοποίηση.

3.1. Διαστάσεις και Βασικά Στατιστικά

Το αρχικό σύνολο δεδομένων περιλαμβάνει 597 μόρια φαρμάκων, καθένα από τα οποία περιγράφεται από 195 μοριακούς περιγραφείς (RDKit descriptors). Περιλαμβάνονται επίσης τα πεδία SMILES (γραμμική αναπαράσταση της μοριακής δομής) και Label (η τιμή-στόχος για ταξινόμηση: 1 = θετική αντίδραση, 0 = αρνητική).

- **Training set:** 477 εγγραφές (118 θετικές, 359 αρνητικές)
- **Test set:** 120 εγγραφές (30 θετικές, 90 αρνητικές)

Δεν εντοπίστηκαν ελλιπή ή μη έγκυρα δεδομένα. Όλοι οι περιγραφείς είναι αριθμητικοί και συνεπώς κατάλληλοι για χρήση σε αλγορίθμους μηχανικής μάθησης.

3.2. Κατανομή Τάξεων


Η κατανομή των κλάσεων είναι έντονα ανισόρροπη:

- DIA-αρνητικά (Label=0): 359 δείγματα (75%)
- DIA-θετικά (Label=1): 118 δείγματα (25%)

Η ύπαρξη αυτής της ανισορροπίας δικαιολογεί την επιλογή μετρικών όπως F1-score, Recall, ROC AUC, αντί της απλής Accuracy, η οποία μπορεί να είναι παραπλανητική.


3.3. Περιγραφική Στατιστική και Κανονικοποίηση

Από την περιγραφική στατιστική των περιγραφέων μέσω `pandas.describe()` προκύπτει έντονη ετερογένεια στις κλίμακες τιμών. Παρακάτω παρουσιάζονται οι κατανομές βασικών στατιστικών:



Σχήμα 1: Κατανομή της τυπικής απόκλισης (std) και της ελάχιστης τιμής (min) στους περιγραφείς.

Η διακύμανση είναι μεγάλη, ένδειξη ασυμμετρίας.



Σχήμα 2: Διαγράμματα διασποράς.

Διαγράμματα διασποράς min vs std και min vs 25% υποδεικνύουν ύπαρξη εξάρσεων σε συγκεκριμένα χαρακτηριστικά.

3.4. Συγκριτική Επισκόπηση Περιγραφών


Για να εντοπιστούν πιθανοί περιγραφείς με έντονες τιμές ή πλεοναστική πληροφορία, παρουσιάζονται διαγράμματα γραμμών βασικών στατιστικών για 5 επιλεγμένους περιγραφείς (BalabanJ, BertzCT, Chi0, Chi0n, κ.λπ.).



Σχήμα 3: Μέσος όρος και count επιλεγμένων περιγραφών. Το χαρακτηριστικό BertzCT παρουσιάζει εξαιρετικά υψηλές τιμές.



Σχήμα 4: Τυπική απόκλιση και ελάχιστες τιμές. Οι τιμές του Chi0 και Chi0n είναι πολύ κοντά στο 0, άρα μικρής πληροφορίας.




Σχήμα 5: Το 25ο τεταρτημόριο επιβεβαιώνει το εύρος συγκέντρωσης τιμών. Δεξιά, η συσσωρευτική διακύμανση δείχνει την αποτελεσματικότητα της PCA.

3.5. Ανάλυση PCA (Principal Component Analysis)

Για σκοπούς μείωσης διαστάσεων και οπτικής επισκόπησης, εφαρμόστηκε PCA στους περιγραφείς. Η καμπύλη σωρευτικής διακύμανσης δείχνει:

- Το 90% της πληροφορίας διατηρείται με τις πρώτες ~75 συνιστώσες.
- Το 95% καλύπτεται με λιγότερες από 100 συνιστώσες.



Σχήμα 6: Προβολή δειγμάτων στις δύο πρώτες συνιστώσες PCA. Δεν υπάρχει ξεκάθαρος διαχωρισμός μεταξύ κλάσεων.

Αν και η PCA συμπιέζει επιτυχώς την πληροφορία, η οπτική αναπαράσταση δεν υποδεικνύει γραμμικό διαχωρισμό των κλάσεων. Επομένως, απαιτούνται μη-γραμμικοί αλγόριθμοι ταξινόμησης (όπως XGBoost, SVM, CatBoost κ.λπ.).

4. Μεθοδολογία

Η διαδικασία ανάπτυξης του συστήματος πρόβλεψης Drug-Induced Autoimmunity (DIA) περιλάμβανε διαδοχικά βήματα που καλύπτουν την προεπεξεργασία δεδομένων, την ενσωμάτωση χημικής πληροφορίας μέσω Tanimoto-γραφικής αναπαράστασης, την αντιμετώπιση της ανισορροπίας, την επιλογή χαρακτηριστικών, την εκπαίδευση μοντέλων και την τελική αξιολόγηση.

4.1. Προεπεξεργασία και Κανονικοποίηση

Αρχικά εφαρμόστηκε MinMax κανονικοποίηση σε όλους τους RDKit descriptors, ώστε να μεταφερθούν εντός του διαστήματος [0,1]. Αφαιρέθηκαν χαρακτηριστικά με μηδενική διακύμανση, επαναλαμβανόμενες στήλες, καθώς και ισχυρά συσχετισμένα ($\text{corr} > 0.95$) χαρακτηριστικά για μείωση του dimensionality και αποφυγή πλεονασμού.

4.2. Εμπλουτισμός Χαρακτηριστικών: Tanimoto Graph Embeddings

Για να ενσωματωθεί η χημική δομή των μορίων στο υπόδειγμα, δημιουργήθηκαν Tanimoto-based γραφήματα ομοιότητας με βάση τα ECFP6 αποτυπώματα [13]. Από τα γραφήματα αυτά εξήχθησαν Laplacian Eigenmaps embeddings ($\text{dim}=64-96$) [1] και εφαρμόστηκε graph smoothing στους descriptors [16]. Επιπρόσθετα, επιλέχθηκαν τα κορυφαία ECFP bits μέσω χ^2 στατιστικής [7] και προστέθηκαν στα τελικά χαρακτηριστικά.

4.3. Αντιμετώπιση Ανισορροπίας

Λόγω της έντονης ανισορροπίας μεταξύ θετικών (25%) και αρνητικών περιπτώσεων, εφαρμόστηκαν:

- **SMOTE** για oversampling της μειονοτικής τάξης ($\text{ratio}=0.8$) [3]
- **Scaffold-aware Cross-Validation** με βάση *Murcko scaffolds* για αποφυγή data leakage [12]
- **Χωρίς class weights** λόγω SMOTE (αποφυγή διπλού ζυγίσματος) [2]
- **Dual-threshold classification** για αβέβαιες προβλέψεις: δύο κατώφλια με ελάχιστη κάλυψη και απόδοση F_β [6]
- **Isotonic calibration** των πιθανοτήτων για αποφυγή overconfidence [15]
- **Seed averaging**: 5 επαναλήψεις ανά μοντέλο με διαφορετικούς random seeds και μέσος όρος πιθανοτήτων [5]

4.4. Επιλογή Χαρακτηριστικών (Feature Engineering)

- SHAP values με βάση XGBoost για αξιολόγηση συνεισφοράς [11]
- Recursive Feature Elimination (RFE) για σταδιακή αφαίρεση [9]
- Genetic Selection μέσω της DEAP (evolutionary optimization για F1) [8]

Το τελικό σύνολο περιλάμβανε ένωση χαρακτηριστικών από τις παραπάνω μεθόδους.

4.5. Μοντέλα και Εκπαίδευση

Εκπαιδεύτηκαν τρία βασικά μοντέλα:

- LogisticRegression (elasticnet penalty): Χρησιμοποιήθηκε με grid search και isotonic calibration.
- RandomForestClassifier: Με 1,000+ trees, optimized hyperparameters, calibrated με isotonic regression.
- XGBClassifier: GPU-accelerated, tuned με RandomizedSearchCV και calibrated.

Όλα τα μοντέλα αξιολογήθηκαν με 5-fold Scaffold Cross-Validation και υπολογίστηκαν οι μετρικές F1-score, Recall, Precision, ROC-AUC. Οι τελικές προβλέψεις βασίστηκαν σε calibrated πιθανότητες και dual-threshold στρατηγική αποφυγής αβεβαιότητας.

5. Αποτελέσματα

Στην ενότητα αυτή παρουσιάζονται αναλυτικά τα αποτελέσματα των τριών βασικών μοντέλων: **XGBoost**, **Random Forest** και **Logistic Regression**. Η αξιολόγηση βασίζεται τόσο σε εκπαίδευση με *seed averaging* και *probability calibration*, όσο και σε μετρικές από single-fit μοντέλα. Επιπλέον, παρουσιάζονται οι καμπύλες ROC και PR καθώς και οι confusion matrices.

5.1. Συγκριτικός Πίνακας Μετρικών

Μοντέλο	Version	Accuracy	Precision	Recall	F1-score	ROC AUC
2*XGBoost	Seed-Avg	0.8917	0.8696	0.6667	0.7547	0.9274
	Single-Fit	0.8750	0.8261	0.6333	0.7170	0.9044
2*Random Forest	Seed-Avg	0.8917	0.8148	0.7333	0.7719	0.9326
	Single-Fit	0.8750	0.8000	0.6667	0.7273	0.9357
2*Logistic Regression	Seed-Avg	0.8583	0.8824	0.5000	0.6383	0.8770
	Single-Fit	0.8583	0.8824	0.5000	0.6383	0.8770

Πίνακας 1: Συγκριτικός πίνακας μετρικών για XGBoost, Random Forest και Logistic Regression (Test Set)


5.2. Ανάλυση Αποτελεσμάτων

Το μοντέλο **XGBoost** εμφάνισε υψηλό **Precision (0.87)** και **ROC AUC (0.927)**, κάτι που δείχνει ισχυρή ικανότητα διαχωρισμού μεταξύ των τάξεων. Ωστόσο, είχε το χαμηλότερο **Recall (0.6667)** σε σχέση με τα άλλα, γεγονός που υποδηλώνει παρουσία ψευδώς αρνητικών προβλέψεων.

Το **Random Forest** πέτυχε την καλύτερη ισορροπία μεταξύ Precision και Recall, με **Recall = 0.7333** και **F1-score = 0.7719**. Το **ROC AUC = 0.933** ήταν το υψηλότερο μεταξύ των τριών μοντέλων, επιβεβαιώνοντας την ανώτερη γενική του επίδοση.

Η **Logistic Regression**, αν και απλούστερο μοντέλο, παρουσίασε εντυπωσιακά υψηλό **Precision (0.8824)**, αλλά χαμηλό **Recall (0.5000)**, κάτι που μεταφράζεται σε περισσότερους ψευδώς αρνητικούς. Η συνολική της ικανότητα διαχωρισμού ήταν ικανοποιητική (**ROC AUC = 0.877**), καθιστώντας τη αξιοπρεπή baseline επιλογή.


5.3. Confusion Matrices




Σχήμα 7: Confusion Matrices για XGBoost, Random Forest και Logistic Regression αντίστοιχα

- Το XGBoost είχε 10 False Negatives (FN), μειώνοντας το recall.
- Το Random Forest είχε μόνο 8 FN και ισορροπημένα True Positives (TP).
- Η Logistic Regression είχε 15 FN και 15 TP, ενδεικτικό χαμηλής ευαισθησίας.

5.4. Καμπύλες Precision-Recall και ROC



Σχήμα 8: Καμπύλες Precision-Recall για XGBoost (AP=0.823), RF (AP=0.817) και LR (AP=0.773)



Σχήμα 9: ROC καμπύλες για XGBoost (AUC=0.927), RF (AUC=0.933) και LR (AUC=0.877)

Η καμπύλη PR του **XGBoost** δείχνει υψηλό precision σε όλο το φάσμα recall, ενώ η **Random Forest** διατηρεί καλύτερη ισορροπία. Η **Logistic Regression** παρουσιάζει απότομη πτώση του precision με αύξηση του recall, δείχνοντας χαμηλότερη αξιοπιστία σε περιοχές υψηλής κάλυψης.

Η καμπύλη ROC του **Random Forest** είναι πιο «τετραγωνισμένη», κοντά στο ιδανικό σημείο (0,1), επιβεβαιώνοντας ότι πρόκειται για το πιο ισχυρό μοντέλο στο συγκεκριμένο dataset.

6. Συμπεράσματα

Η παρούσα μελέτη στόχευσε στην ανάπτυξη και αξιολόγηση ταξινομητικών μοντέλων για την ανίχνευση θετικών περιπτώσεων (DIA+) σε ένα ανισόρροπο σύνολο μοριακών δεδομένων. Δόθηκε ιδιαίτερη έμφαση στην αντιμετώπιση της ανισορροπίας μεταξύ των τάξεων, στην αξιολόγηση της αξιοπιστίας των προβλέψεων, και στη συγκριτική ανάλυση διαφορετικών αλγορίθμων.

Απόδοση Μοντέλων: Τα μοντέλα που εξετάστηκαν ήταν τα **XGBoost**, **Random Forest** και **Logistic Regression**, εφαρμόζοντας τεχνικές όπως *SMOTE*, *seed averaging*, *isotonic calibration* και *dual-threshold classification*.

- Το **Random Forest** κατέγραψε την καλύτερη ισορροπία μεταξύ **Precision** και **Recall**, επιτυγχάνοντας $F1\text{-score} = 0.7719$ και $ROC\ AUC = 0.933$. Η απόδοσή του υποδηλώνει αυξημένη ικανότητα στην αναγνώριση θετικών περιπτώσεων χωρίς σημαντική αύξηση των ψευδών θετικών.
- Το **XGBoost**, παρότι εμφάνισε την υψηλότερη ακρίβεια ($Precision = 0.8696$), υστέρησε ελαφρώς στο **Recall** (0.6667), ενισχύοντας την υπόθεση ότι είναι πιο «συντηρητικό» στην πρόβλεψη θετικών περιπτώσεων.
- Το **Logistic Regression**, αν και παρουσίασε την πιο απλή και ερμηνεύσιμη αρχιτεκτονική, είχε σημαντικά χαμηλότερο **Recall** (0.5000), οδηγώντας σε υψηλότερο ποσοστό μη ανιχνευμένων θετικών περιπτώσεων. Ωστόσο, πέτυχε υψηλό **Precision** (0.8824) και $AUC = 0.877$, καθιστώντας το μια σταθερή baseline επιλογή.

Γενικές Παρατηρήσεις: Η χρήση **Seed Averaging** βοήθησε στη σταθεροποίηση των αποτελεσμάτων, περιορίζοντας την επίδραση της στοχαστικότητας στην εκπαίδευση. Η **Isotonic Calibration** βελτίωσε την αξιοπιστία των πιθανοτήτων εξόδου, κάτι που αποτυπώνεται στη βελτιωμένη συμπεριφορά των PR καμπυλών. Επιπλέον, η **dual-threshold προσέγγιση** επέτρεψε τον καθορισμό ζωνών χαμηλής εμπιστοσύνης, αυξάνοντας τη χρηστικότητα του συστήματος σε πραγματικά σενάρια.

Εφαρμοστική Σημασία: Για εφαρμογές όπου η αναγνώριση των θετικών περιπτώσεων είναι κρίσιμη (π.χ. φαρμακευτική ανακάλυψη ή τοξικολογική αξιολόγηση), το **Random Forest** συνιστάται ως το καταλληλότερο μοντέλο. Αντίθετα, σε περιβάλλοντα όπου οι ψευδώς θετικές προβλέψεις πρέπει να ελαχιστοποιούνται, το **XGBoost** μπορεί να είναι πιο κατάλληλο.

Συνολικά, η μεθοδολογική προσέγγιση που εφαρμόστηκε κατέδειξε ότι ακόμη και σε ανισόρροπα προβλήματα, η προσεκτική προεπεξεργασία, ο στρατηγικός χειρισμός των thresholds και η ορθή αξιολόγηση μπορούν να οδηγήσουν σε μοντέλα με ισχυρή γενικευσιμότητα και υψηλή απόδοση.

Αναφορές

- [1] M. Belkin and P. Niyogi, *Laplacian Eigenmaps for Dimensionality Reduction and Data Representation*, Neural Computation, vol. 15, no. 6, pp. 1373–1396, 2003.

- [2] M. Buda, A. Maki, and M. A. Mazurowski, *A Systematic Study of the Class Imbalance Problem in Convolutional Neural Networks*, Neural Networks, vol. 106, pp. 249--259, 2018.
- [3] N. V. Chawla, K. W. Bowyer, L. O. Hall, and W. P. Kegelmeyer, *SMOTE: Synthetic Minority Over-sampling Technique*, Journal of Artificial Intelligence Research, vol. 16, pp. 321--357, 2002.
- [4] Delfiero et al., *Comparative study of ML algorithms for predicting drug-induced autoimmunity using molecular descriptors*, Jurnal Mandiri IT, vol. 14, no. 1, pp. 180--190, 2025.
- [5] T. G. Dietterich, *Ensemble Methods in Machine Learning*, International Workshop on Multiple Classifier Systems, Springer, pp. 1--15, 2000.
- [6] C. Elkan, *The Foundations of Cost-Sensitive Learning*, Proceedings of the 17th International Joint Conference on Artificial Intelligence (IJCAI), 2001.
- [7] G. Forman, *An Extensive Empirical Study of Feature Selection Metrics for Text Classification*, Journal of Machine Learning Research, vol. 3, pp. 1289--1305, 2003.
- [8] F.-A. Fortin, F.-M. De Rainville, M.-A. Gardner, M. Parizeau, and C. Gagné, *DEAP: Evolutionary Algorithms Made Easy*, Journal of Machine Learning Research, vol. 13, pp. 2171--2175, 2012.
- [9] I. Guyon, J. Weston, S. Barnhill, and V. Vapnik, *Gene Selection for Cancer Classification using Support Vector Machines*, Machine Learning, vol. 46, no. 1--3, pp. 389--422, 2002.
- [10] Huang et al., *InterDIA: Interpretable Prediction of Drug-induced Autoimmunity through Ensemble Machine Learning Approaches*, Toxicology, vol. 511, 2025.
- [11] S. M. Lundberg and S.-I. Lee, *A Unified Approach to Interpreting Model Predictions*, Advances in Neural Information Processing Systems (NeurIPS), vol. 30, pp. 4765--4774, 2017.
- [12] P. G. Polishchuk, T. I. Madzhidov, and A. Varnek, *Estimation of the Size of Drug-like Chemical Space Based on GDB-17 Data*, Journal of Computer-Aided Molecular Design, vol. 27, no. 8, pp. 675--679, 2013.
- [13] D. Rogers and M. Hahn, *Extended-Connectivity Fingerprints*, Journal of Chemical Information and Modeling, vol. 50, no. 5, pp. 742--754, 2010.
- [14] UCI Machine Learning Repository. *Drug Induced Autoimmunity Prediction Dataset*.
https://archive.ics.uci.edu/dataset/1104/drug_induced_autoimmunity_prediction
- [15] B. Zadrozny and C. Elkan, *Transforming Classifier Scores into Accurate Multiclass Probability Estimates*, Proceedings of the 8th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, pp. 694--699, 2002.
- [16] D. Zhou, O. Bousquet, T. N. Lal, J. Weston, and B. Schölkopf, *Learning with Local and Global Consistency*, Advances in Neural Information Processing Systems (NeurIPS), vol. 16, pp. 321--328, 2004.